

## 12. 独立成分分析（ICA）

### 1. 独立成分分析的不确定性（ICA ambiguities）

### 2. 密度函数和线性变换

### 3. 独立成分分析算法

接下来我们要讲的就是**独立成分分析**（Independent Components Analysis, ICA）算法。这个方法和主成分分析（PCA）类似，也是要找到一组新的**基向量**（basis）来**表征**（represent）样本数据。然而，这两个方法的目的却截然不同。

我们还以“鸡尾酒会问题”为例。在一个聚会中，有  $n$  个人同时说话，并且放置在房间内的任何话筒仅记录这  $n$  个人叠加在一起的声音。如果假设我们也有  $n$  个不同的话筒安装在屋子里，并且这些话筒与每个说话人的距离都各自不同，那么记录的也就是不同组合形式的叠加声音。使用这样布置的  $n$  个话筒来录音，能不能区分开原始的  $n$  个说话者每个人的声音信号呢？

把这个问题用方程的形式来表示，我们需先假设时刻  $i$  有某样本数据  $s^{(i)} = (s_1^{(i)}, s_2^{(i)}, \dots, s_n^{(i)})^T \in R^n$ ，这个数据是由  $n$  个**独立的源**（independent sources）在时刻  $i$  生成的，例如  $s_j^{(i)}$  是第  $j$  个说话者在时刻  $i$  发出的声音。总样本数据为  $s = (s^{(1)}, s^{(2)}, \dots, s^{(m)}) \in R^{n \times m}$ ，表示  $n$  个说话者在  $m$  个时刻中生成的总数据。我们观察到的则为：

$$\begin{aligned}x^{(i)} &= As^{(i)} \\x &= As\end{aligned}$$

上面式子中的  $A$  是一个未知的方形矩阵，叫做**混合矩阵**（mixing matrix）。通过重复的观察，我们就得到了训练样本  $x = \{x^{(i)}; i = 1, \dots, m\} \in R^{n \times m}$ ，其中  $x^{(i)}$  类似于  $s^{(i)}$ ，例如  $x_j^{(i)}$  是第  $j$  个话筒在时刻  $i$  记录的声音。我们的目的是恢复出这些样本  $x^{(i)} = As^{(i)}$  的原始声音源  $s^{(i)}$ 。

$$x = \begin{bmatrix} | & | & & | \\ x^{(1)} & x^{(2)} & \dots & x^{(m)} \\ | & | & & | \end{bmatrix} = \begin{bmatrix} | & | & & | \\ As^{(1)} & As^{(2)} & \dots & As^{(m)} \\ | & | & & | \end{bmatrix} = A \begin{bmatrix} s_1^{(1)} & s_1^{(2)} & \dots & s_1^{(m)} \\ s_2^{(1)} & s_2^{(2)} & \dots & s_2^{(m)} \\ \vdots & \vdots & \ddots & \vdots \\ s_n^{(1)} & s_n^{(2)} & \dots & s_n^{(m)} \end{bmatrix} = As$$

令  $W = A^{-1}$ ，称之为**还原矩阵**（unmixing matrix）。我们的目标就是找到  $W$ ，这样针对给定的  $x^{(i)}$ ，就可以通过计算  $s^{(i)} = Wx^{(i)}$  来还原出声音源。为了方便，我们用  $w_j^T$  来表示  $W$  的第  $j$  行，如下：

$$W = \begin{bmatrix} w_1^T \\ \vdots \\ w_n^T \end{bmatrix}$$

其中， $w_j \in R^n$ ，然后就可以通过计算  $s_j^{(i)} = w_j^T x_j^{(i)}$  恢复出第  $j$  个声源了。

## 1. 独立成分分析的不确定性（ICA ambiguities）

下面是两个独立成分分析的不确定性：

第一个，由于  $W$  和  $s$  都不确定，那么在没有先验证知识的情况下，无法同时确定这两个相关参数。比如上面的公式  $s = Wx$ 。当  $W$  扩大两倍时， $s$  只需要扩大两倍即可，等式仍然成立，因此无法得到唯一的  $s$ 。

第二个，如果将  $s$  的顺序打乱，变成另外一个顺序，那么只需要调整  $A$  的列向量顺序即可，因此也无法单独确定  $s$ 。

另外，还有一种独立成分分析不适用的情况，那就是信号不能是**高斯分布**的。当源信号是高斯分布的时候，可以由不同的混合矩阵  $A$  乘以  $s$ ，得到相同的  $x$ ，一样无法确定源信号。

## 2. 密度函数和线性变换

在继续推导独立成分分析（ICA）算法之前，我们先来简要讲一讲线性变换对密度函数的影响（effect）。

假设我们有一个概率密度函数为  $p_s(s)$  的随机变量  $s$ 。简单起见，我们把  $s$  当做一个实数，即  $s \in R$ 。然后，设又有一随机变量  $x$ ， $x$  定义为  $x = As$ 。那么  $x$  的概率密度函数  $p_x(x)$  是多少呢？在计算之前，我们先讨论一下**概率分布函数**  $F(x) = P(X \leq x)$  与**概率密度函数**  $f(x) = p(x)$  之间的关系吧，事实上，概率分布函数是概率密度函数的积分，概率密度函数是概率分布函数的导数，二者关系如下：

$$F(x) = \int_{-\infty}^x f(x)dx$$
$$f(x) = F'(x)$$

因此，关于  $p_x(x)$  的推导如下：

$$F_x(x) = P(X \leq x) = P(As \leq x) = P(s \leq Wx) = F_s(Wx)$$
$$p_x(x) = F'_x(x) = F'_s(Wx) = p_s(Wx)|W|$$

即， $p_x(x) = p_s(Wx)|W|$ （ $|W|$  其实也可以分步求导解释）

## 3. 独立成分分析算法

现在就可以推导独立成分分析（ICA）算法了。我们这里描述的算法来自于 Bell 和 Sejnowski，对算法的解释使用**最大似然估计**的方法。我们假设每个声源的分布  $s_i$  的概率密度函数为  $p_s$ ，那么联合分布  $s$  则为：

$$p(s) = \prod_{i=1}^n p_s(s_i)$$

这里要注意，由于我们假设每个声源都是独立的，故可以在建模中将联合分布直接写成边界分布的乘积。利用上一节推导的结论，这就表明  $x = As = W^{-1}s$  的密度函数为：

$$p(x) = p_s(Wx)|W| = |W| \prod_{i=1}^n p_s(w_i^T x)$$

剩下的就是为单个源  $p_s$  指定一个密度。回忆一下，给定一个实数值的随机变量  $z$ ，其累积分布函数（即概率分布函数） $F$  的定义为： $F(z_0) = P(z \leq z_0) = \int_{-\infty}^{z_0} p_z(z)dz$ 。然后对这个累积分布函数求导，就能得到  $z$  的密度函数： $p_z(z) = F'(z)$ 。

因此，要确定  $s_i$  的密度函数，首先要做的就是确定其累积分布函数。根据我们之前的讨论，这里不能选用高斯分布的累积分布函数，因为独立成分分析不适用于高斯分布的数据。这里我们选择一个保证从 0 到 1 单调递增函数即可，比如  $s$  形函数（sigmoid function） $g(s) = 1/(1 + e^{-s})$ 。这样就有： $p_s(s) = g'(s)$ 。

模型中的参数  $W$  是一个正方形矩阵。给定一个训练集合  $\{x^{(i)}; i = 1, \dots, m\}$ ，对数似然函数则为：

$$l(W) = \sum_{i=1}^m \left( \sum_{j=1}^n \log g'(w_j^T x^{(i)}) + \log |W| \right)$$

我们要做的就是选择合适的  $W$  最大化上式。通过求导和前面讲义中的定理： $\nabla_W |W| = |W|(W^{-1})^T$ ，就可以很容易推导出**随机梯度上升**的学习规则。对一个给定的训练样本  $x^{(i)}$ ，这个更新规则为：

$$W := W + \alpha \left( \begin{bmatrix} 1 - 2g(w_1^T x^{(i)}) \\ 1 - 2g(w_2^T x^{(i)}) \\ \vdots \\ 1 - 2g(w_n^T x^{(i)}) \end{bmatrix} x^{(i)T} + (W^T)^{-1} \right)$$

上式中的  $\alpha$  是学习速率。在算法收敛之后，就能计算出  $s^{(i)} = Wx^{(i)}$ ，这样就能恢复出原始的音源了。